

UNIVERSIDAD LIBRE — SECCIONAL CALI

FACULTAD DE INGENIERÍA

PROGRAMA DE CIENCIA DE DATOS

**PRODUCTO DE DATOS PARA EL MONITOREO, LA EXPLICACIÓN
Y EL PRONÓSTICO DE INDICADORES AGREGADOS DE LAS
IMPORTACIONES Y LA CARGA PORTUARIA DE BUENAVENTURA**

JUAN MANUEL TEJADA FAJARDO

JESÚS ALEJANDRO GUERRERO

Director del trabajo: Ing. Fabián Castillo

Ingeniería del Producto de Ciencia de Datos

SANTIAGO DE CALI

2026

Contenido

1. Introducción
2. Descripción de los procesos generales
3. Planteamiento y formulación del problema
4. Objetivos
5. Justificación
6. Alcance del trabajo
7. Delimitación
8. Marco de referencia
9. Metodología
10. Ingeniería del producto de datos
11. Resultados del análisis exploratorio
12. Resultados del modelado
13. Modelo de negocios
14. Estrategias de comunicación
15. Conclusiones
16. Recomendaciones
17. Fuentes de información
- Anexo A. Matriz de trazabilidad P01–P52
- Anexo B. Reporte de no viabilidad
- Anexo C. Preparación para la sustentación

1. Introducción

Buenaventura concentra una parte central del comercio exterior colombiano por el Pacífico. La información que lo describe existe y es pública, pero vive en fuentes separadas que miden cosas distintas. El Departamento Administrativo Nacional de Estadística publica las declaraciones de importación, donde el dato central es el valor CIF y el peso neto de la mercancía. La Superintendencia de Transporte publica las toneladas movilizadas por las sociedades portuarias, que incluyen el embalaje y cubren además exportación y transbordo.

Que ambas existan no significa que puedan compararse sin cuidado. Una registra operaciones aduaneras bajo el código 35; la otra registra movimientos de carga en la zona portuaria. No comparten unidad, ni cobertura, ni identificador. Tampoco existe una llave pública que permita saber en qué buque llegó una importación concreta.

Este trabajo las integra por mes calendario. El dominio aduanero aporta 173 meses (2012-01 a 2026-05), contruidos a partir de 6.703.351 registros. El portuario aporta 102 meses (2018-01 a 2026-06). El periodo en que ambos coexisten es de 101 meses (2018-01 a 2026-05).

La integración permite algo que ninguna fuente logra por separado: distinguir si un cambio en el comercio se debe a que entró más mercancía o a que la mercancía vale más por kilogramo. El producto incluye además un componente predictivo acotado, con intervalos cuya cobertura se mide en lugar de declararse.

Un resultado del trabajo contradice la hipótesis con la que se inició: sumar variables portuarias no mejora el pronóstico del valor CIF, lo empeora. El aporte de la integración es descriptivo y explicativo, no predictivo.

2. Descripción de los procesos generales

El producto se construye mediante un flujo de catorce pasos encadenados. Cada paso deja un archivo verificable, de modo que cualquier cifra del documento puede rastrearse hasta su origen.

Tabla 1. Procesos generales del producto de datos

Paso	Proceso	Salida
1	Identificación y evaluación de fuentes	catalogo_fuentes.csv
2	Descarga y conservación de datos originales	capa raw inmutable
3	Control de integridad con hashes	manifest_fuentes.csv
4	Homologación de formatos entre vigencias	cambios_esquema.csv
5	Validación de estructura, unidades y continuidad	calidad_portuaria.csv
6	Agregación mensual por dominio	capa trusted
7	Integración por mes calendario	vista_integrada_mensual.parquet (capa trusted)
8	Respuesta o cierre documentado de las 52 preguntas	matriz trazabilidad_edc.csv
9	Selección de indicadores pronosticables	elegibilidad_indicadores.csv
10	Validación temporal walk-forward	metricas_modelos_portuarios.csv
11	Construcción y medición de intervalos	cobertura_intervalos_portuarios.csv
12	Generación de archivos de consumo	capa surface
13	Visualización en tablero	dashboard de seis vistas
14	Documentación y trazabilidad	lista_cifras.csv y este documento

Fuente: Elaboración propia a partir del flujo implementado en el repositorio del proyecto.

El flujo se organiza en cuatro capas sucesivas. La capa raw guarda los archivos originales sin modificar, con su hash. La capa landing unifica formatos. La capa trusted contiene las series validadas. La capa surface reúne las salidas que consume el tablero. Los cuadernos orquestan el flujo y la lógica reutilizable vive en módulos cubiertos por pruebas automatizadas.

3. Planteamiento y formulación del problema

3.1 Planteamiento del problema

Un analista que quiera entender el comercio de Buenaventura se encuentra con tres dificultades encadenadas. La primera es de acceso: los microdatos aduaneros se publican en paquetes comprimidos anuales que hay que descargar y descomprimir uno por uno, y las estadísticas portuarias viven en otro portal, con otra estructura.

La segunda es de formato. Los microdatos aduaneros cambian de estructura cinco veces entre 2012 y 2026: varía el separador, la convención decimal, la codificación del archivo y el número de columnas. Un cambio de convención decimal no genera un error visible, genera números mal leídos que se suman igual.

La tercera es conceptual y es la más costosa. El valor CIF y el peso neto miden cosas distintas, y su cociente es un valor unitario que no debe confundirse con un precio. Sin contrastar las tres magnitudes, una variación monetaria puede leerse como si fuera un cambio en la cantidad de mercancía. Del lado portuario ocurre algo equivalente: el total incluye transbordo, que es carga que cambia de buque sin entrar al país.

3.2 Formulación del problema

¿Cómo desarrollar un producto de datos reproducible que integre información aduanera y portuaria de Buenaventura, permita monitorear y explicar indicadores agregados, pronostique únicamente aquellos con historia y calidad suficientes, comunique la incertidumbre de forma calibrada y no afirme relaciones que las fuentes no permiten sostener?

4. Objetivos

4.1 Objetivo general

Desarrollar y validar un producto de datos reproducible que integre información aduanera y portuaria de Buenaventura para monitorear, explicar y pronosticar indicadores agregados, conservando la trazabilidad desde la fuente oficial hasta la salida de consumo.

4.2 Objetivos específicos y evidencia de cumplimiento

Tabla 2. Objetivos específicos y su evidencia de cumplimiento

Objetivo	Evidencia	Resultado
Evaluar la viabilidad de fuentes en cuatro dominios	catalogo_fuentes.csv, reporte_no_viabilidad.csv	6 fuentes evaluadas, 2 integradas, 2 de contexto, 2 descartadas
Construir series mensuales reconciliadas por dominio	serie_aduanera_mensual.parquet , serie_portuaria_mensual.parquet	173 y 102 meses continuos
Responder o cerrar con evidencia documentada las 52 preguntas del análisis exploratorio	matriz_trazabilidad_edc.csv	38 ejecutadas, 4 parciales, 10 no viables
Declarar el tipo de integración posible y sus límites	matriz_integracion.csv	integración agregada por mes; ninguna directa
Determinar qué indicadores pueden pronosticarse	elegibilidad_indicadores.csv	4 elegibles de 7 evaluados
Medir si la integración mejora el pronóstico	ablacion_multidominio.csv	no lo mejora: pasa de 6,082 % a 6,575 %
Comunicar la incertidumbre con cobertura medida	cobertura_intervalos_portuarios.csv	cobertura empírica entre 75,0 % y 91,7 %
Documentar con evidencia lo no viable	reporte_no_viabilidad.csv	10 preguntas cerradas con búsqueda documentada

Fuente: Elaboración propia. Cada evidencia es un archivo generado por el pipeline.

5. Justificación

Buenaventura constituye un nodo relevante del comercio exterior colombiano sobre el Pacífico. Los datos que lo describen son públicos, pero llegar a una lectura útil de ellos exige un trabajo técnico que hoy debe rehacerse cada vez: descargar paquetes anuales, homologar formatos que cambian, validar unidades y agregar series.

Ese trabajo repetido es lo que el producto automatiza. Una vez construido el flujo, actualizar el análisis con un mes nuevo deja de ser un proyecto y pasa a ser una ejecución. Ese cambio es lo que separa un análisis puntual de un producto de datos.

El proyecto tiene además valor analítico propio. Distinguir valor, peso y valor unitario implícito permite evaluar si un mes cambió principalmente por una mayor cantidad importada o por un mayor valor agregado por kilogramo, una pregunta que un total agregado no responde. Separar el transbordo del comercio exterior evita leer como caída del comercio lo que es un cambio en el uso del puerto como punto de conexión entre buques.

Desde la ciencia de datos, el trabajo aporta un ejercicio poco frecuente en proyectos de este nivel: comparar el modelo contra tres líneas base y no contra una sola. Reportar únicamente la referencia estacional hacía parecer que el modelo mejoraba un 64,4 %, cuando frente a la referencia exigente la mejora real es del 15,5 %.

5.1 Usuarios potenciales

- Analistas de comercio exterior que preparan informes mensuales.
- Observatorios económicos regionales y centros de estudios.
- Gremios de comercio exterior y agencias de aduanas.
- Investigadores y estudiantes que necesiten una serie ya reconciliada.
- Entidades públicas que requieran una lectura conjunta de ambos dominios.

6. Alcance del trabajo

El trabajo comprende de forma explícita:

- Integración de los microdatos aduaneros del DANE para la aduana 35.
- Integración del tráfico portuario de la zona de Buenaventura.
- Unión agregada de ambos dominios por mes calendario.
- Análisis exploratorio de las 52 preguntas del catálogo, respondidas o cerradas con evidencia documentada por pregunta.
- Pronóstico de los indicadores que cumplen los criterios de elegibilidad.

- Intervalos de predicción con cobertura empírica medida.
- Reglas de alerta de tres niveles calibradas con la ventana de entrenamiento.
- Tablero de consulta de seis vistas que lee de la capa de salidas.
- Trazabilidad de cada cifra hasta un archivo del pipeline.

7. Delimitación

Las siguientes delimitaciones no son advertencias formales: cada una responde a una característica concreta de las fuentes y define el borde de lo que el producto puede afirmar.

Tabla 3. Delimitaciones del producto y su origen en las fuentes

Delimitación	Qué significa
Aduana 35	Es una unidad de registro administrativo, no una instalación física
Sociedad portuaria	La fuente identifica la razón social que reporta, que puede administrar una o varias instalaciones
CIF por kilogramo	Valor unitario implícito afectado por mezcla, seguro y flete. No es un precio
Transbordo	Carga que cambia de buque sin entrar al país. No es comercio exterior
Llave declaración-buque	No existe llave pública. La integración es agregada por mes, nunca directa
Tiempos operativos	ETA, ATA, permanencias y congestión no tienen fuente pública histórica
TEU	La fuente publica toneladas por tipo de carga, no unidades de contenedor
Unidad monetaria	El valor CIF está en dólares corrientes: su variación puede reflejar cambios en precios, flete, seguro y mezcla de mercancías.
Alertas	Son señales de revisión analítica, no órdenes operativas

Fuente: Elaboración propia a partir de la documentación oficial de cada fuente.

8. Marco de referencia

8.1 Marco conceptual

Los términos que el documento usa con un sentido preciso son los siguientes.

Tabla 4. Conceptos del dominio

Término	Definición aplicada
Valor CIF	Valor de la mercancía más seguro y flete hasta el

Término	Definición aplicada
	punto de entrada, en dólares corrientes
Peso neto	Peso de la mercancía sin embalaje, en kilogramos
Valor unitario implícito	Cociente entre valor CIF y peso neto de los agregados mensuales. No es un precio
Toneladas movilizadas	Carga registrada por las sociedades portuarias, con embalaje incluido
Importación	Carga que ingresa al territorio aduanero
Exportación	Carga que sale del territorio aduanero
Transbordo	Carga que cambia de buque sin entrar ni salir del país
Sociedad portuaria	Razón social que reporta movimientos de carga a la Superintendencia de Transporte

Fuente: Elaboración propia a partir de DANE (2026) y Superintendencia de Transporte (2026).

Tabla 5. Conceptos metodológicos

Término	Definición aplicada
HHI	Suma de los cuadrados de las participaciones porcentuales. Por encima de 2.500 se considera concentrado
WAPE	Suma de errores absolutos dividida por la suma de valores observados, en porcentaje
MASE	Error absoluto medio escalado por el error de una referencia ingenua. Menor que 1 significa que supera esa referencia
Naive 1	Predcir que el mes siguiente será igual al último observado
Naive 12	Predcir el valor del mismo mes del año anterior
Drift	Extrapolar la pendiente media de toda la serie
Walk-forward	En cada corte se entrena con el pasado y se predice el mes siguiente, respetando el orden temporal
Intervalo de predicción	Rango construido con los cuantiles de los errores fuera de muestra, cuya cobertura se mide
Trazabilidad	Posibilidad de rastrear una cifra hasta el archivo y la línea de código que la produjo
Capas raw, landing, trusted, surface	Original inmutable, homologado, validado y listo para consumo

Fuente: Elaboración propia a partir de Hyndman y Athanasopoulos (2021).

8.2 Marco normativo

- Ley 1712 de 2014, de transparencia y acceso a la información pública, que sustenta el uso de datos abiertos con cita de la fuente.
- Ley 1581 de 2012, de protección de datos personales. La capa analítica utilizada por el proyecto no incorpora identificadores personales ni empresariales del importador.
- NTC 1486 del ICONTEC, aplicada a márgenes, numeración y presentación de este documento.
- Normas APA en su séptima edición, aplicadas a citas y referencias.

- Condiciones de uso del DANE, que exigen una cita textual de la fuente y restringen la reproducción de los microdatos originales.
- Licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional del conjunto de tráfico portuario, que obliga a citar y a compartir los derivados bajo la misma licencia.

8.3 Antecedentes

Las estadísticas de comercio exterior colombiano se publican de forma periódica desde 1916. Desde 1993 la Dirección de Impuestos y Aduanas Nacionales produce la información y el DANE la valida y difunde, con un plazo máximo de cuarenta y cinco días posteriores al mes de referencia. Esa división institucional explica parte del rezago de publicación con el que trabaja el producto.

Los microdatos aduaneros se distribuyen en dos catálogos distintos según el periodo, con formatos que cambiaron cinco veces en el intervalo analizado. Las estadísticas portuarias, en cambio, mantienen un esquema estable desde 2018, aunque su publicación es trimestral pese a que el dato es mensual.

Para el dominio marítimo, la Dirección General Marítima publica boletines trimestrales agregados en formato PDF. No se localizó una serie histórica tabular con desagregación por evento, lo que impide construir indicadores de arribos, tipos de buque o tiempos operativos con fuentes públicas. Esa ausencia es la que define el alcance real del proyecto.

9. Metodología

El trabajo es una investigación aplicada, cuantitativa y longitudinal. Cada fase produce una evidencia verificable, y ninguna cifra llega a este documento sin pasar antes por un archivo generado por el pipeline.

9.1 Preparación de los datos

Los archivos originales se conservan sin modificar y se registran con su hash, de modo que puede demostrarse meses después que no cambiaron. La

homologación detecta automáticamente el separador y la convención decimal de cada vigencia, y lee los códigos como texto para no perder los ceros iniciales. Ninguna corrección ocurre en silencio: cada exclusión queda registrada con su regla.

9.2 Validación temporal

La evaluación usa validación walk-forward de un paso. En términos sencillos: el modelo se sitúa en cada mes del pasado, se entrena únicamente con lo anterior y predice el mes siguiente; después se compara con lo que realmente ocurrió. Se repite ese ejercicio veinticuatro veces.

Toda transformación que dependa de los datos, incluidos los escaladores, se ajusta dentro del conjunto de entrenamiento de cada corte. Si se ajustara sobre la serie completa, el modelo estaría usando información del futuro para preparar el pasado, y su desempeño aparente sería mejor que el real.

9.3 Prevención de fuga de información

Todas las variables predictoras se construyen con datos anteriores al mes que se predice. Las medias móviles se calculan sobre la serie ya desplazada. Las únicas variables sin rezago son las de calendario, que se conocen de antemano. Existe una prueba automatizada que detiene el proceso si alguna variable presenta correlación casi perfecta con el objetivo del mismo mes.

9.4 Líneas base y métricas

Se reportan siempre tres referencias: repetir el último valor, repetir el mismo mes del año anterior y extrapolar la pendiente. Reportar solo una puede exagerar la mejora atribuible al modelo. Las métricas incluyen WAPE, MASE, sesgo y error máximo, porque un promedio bajo puede ocultar un mes con un error grave o un sesgo sistemático hacia un lado.

9.5 Intervalos de predicción

Los intervalos se construyen con los cuantiles de los errores fuera de muestra del propio backtest, con calibración expansiva: para cada corte se usan únicamente los errores anteriores. No se derivan de ninguna métrica de error puntual. Si la cobertura medida no alcanza el nivel declarado, el intervalo se recalibra o se renombra según lo que realmente cubre.

9.6 Criterios de elegibilidad y de no viabilidad

Un indicador entra al componente predictivo si tiene al menos treinta y seis observaciones mensuales, continuidad completa y un rezago de publicación conocido. El criterio se fijó antes de mirar los resultados. Una pregunta se cierra como no viable cuando se documenta dónde se buscó la fuente, qué se encontró y qué haría falta para responderla en una fase posterior.

9.7 Análisis de ablación

La ablación consiste en entrenar el mismo modelo con distintos grupos de variables y comparar su desempeño sobre los mismos cortes. Sirve para responder si una variable aporta, en lugar de suponerlo. Es el método con el que se evaluó si integrar el dominio portuario mejora el pronóstico aduanero.

10. Ingeniería del producto de datos

10.1 Arquitectura por capas

Tabla 6. Capas de datos y su garantía

Capa	Contenido	Garantía
raw	Archivos originales sin modificar	Hash SHA-256 por archivo
landing	Datos homologados entre vigencias	Registro de formatos y exclusiones
trusted	Series mensuales validadas	Continuidad y reconciliación
surface	Métricas, pronósticos y evidencia	Cada archivo enlazado a una pregunta

Fuente: Elaboración propia.

10.2 Pipeline

Las entradas son los paquetes anuales del DANE y la consulta a la interfaz de datos abiertos de la Superintendencia. Las transformaciones incluyen detección de formato, filtro por aduana, conversión de tipos, agregación mensual y cálculo del valor unitario implícito. Las validaciones cubren esquema, duplicados, continuidad, dominios y reconciliación. Las salidas son los archivos de la capa de consumo, las figuras y la matriz de trazabilidad.

10.3 Integración de dominios

La integración es agregada por mes calendario. No existe llave pública que relacione una declaración de importación con un movimiento de carga portuaria, y no se construyó ninguna por inferencia. Cada relación entre fuentes está declarada como directa, agregada, contextual o no viable.

Tabla 7. Relaciones entre fuentes y tipo de integración

Origen	Destino	Llave	Tipo
DANE IMPO (declaraciones)	Supertransporte (tráfico)	mes calendario	agregada
DANE IMPO	TRM	mes calendario	agregada
DANE IMPO	ONI	mes calendario	contextual
DANE IMPO	Catálogo de eventos	rango de fechas	contextual
Supertransporte	DIMAR (arribos)	—	no viable
Cualquiera	ETA/ATA/permanencias	—	no viable

Fuente: Elaboración propia. Salida del pipeline: matriz_integracion.csv (P42).

10.4 Calidad y trazabilidad

El proyecto cuenta con 80 pruebas automatizadas que verifican las reglas del propio producto: que las variables no miren al futuro, que los intervalos no se deriven de una métrica puntual, que la numeración de las preguntas no cambie y que una pregunta sin salida no se marque como ejecutada. El cuaderno del análisis exploratorio produce 55 figuras y 57 archivos de evidencia.

Existe además una lista de cifras que asocia cada valor citado con su archivo de origen y su pregunta. La construcción de este documento falla si se solicita una

cifra que no esté en esa lista, lo que impide que un número escrito a mano llegue al texto.

10.5 Modelado

Los objetivos evaluados fueron el valor CIF, el peso neto, las toneladas totales y la carga contenerizada. Las variables predictoras son rezagos del propio indicador, medias móviles desplazadas, variables de calendario y, en los conjuntos de prueba, la tasa representativa del mercado y el índice oceánico. Los resultados se detallan en el capítulo 12.

10.6 Tablero de consulta

Tabla 8. Vistas del tablero de consulta

Vista	Contenido
Ejecutiva	Valor económico y volumen físico lado a lado
Aduanera	CIF, peso neto, valor unitario y estacionalidad
Portuaria	Tipos de carga, sociedades, concentración y especialización
Marítima	Documentación de la no viabilidad del dominio
Predictiva	Modelos, líneas base, intervalos y ablación
Calidad	Trazabilidad de las 52 preguntas y fuentes

Fuente: Elaboración propia. El tablero lee de la capa de salidas y no calcula cifras propias.

El tablero no realiza ningún cálculo: lee exclusivamente los archivos que produce el pipeline. Si un archivo falta, la vista lo indica en lugar de mostrar un valor estimado. Esa decisión de diseño garantiza que lo que se ve en pantalla y lo que dice este documento provienen del mismo origen.

11. Resultados del análisis exploratorio

11.1 Estado de las 52 preguntas

Tabla 9. Estado de las 52 preguntas del análisis exploratorio

Estado	Preguntas
ejecutada	38
no viable	10
parcial	4

Fuente: Elaboración propia. Salida del pipeline: matriz_trazabilidad_edc.csv.

Ninguna pregunta quedó sin respuesta. Las cerradas como no viables documentan dónde se buscó, qué se encontró y qué fuente haría falta. La especificación del análisis admite esa respuesta siempre que esté demostrada.

11.2 Valor económico frente a volumen físico

Sobre los 101 meses comunes, el valor CIF creció un 80,4 % entre los primeros y los últimos doce meses. Descomponiendo ese crecimiento en logaritmos, el volumen aporta el 52,2 % y el valor unitario el 47,0 %. La suma no alcanza exactamente el cien por ciento porque la media de un cociente no coincide con el cociente de las medias; ese residuo es de menos de un punto.

Alrededor de la mitad del crecimiento del valor importado corresponde a más mercancía y la otra mitad a mercancía más cara por kilogramo. Un total agregado no permite distinguirlo.

El valor unitario implícito medio del periodo completo es de 1,2368 dólares por kilogramo. Conviene insistir en que no es un precio: lo afectan la mezcla de mercancías, el seguro y el flete.

11.3 El total portuario y sus componentes

El tráfico portuario agregado combina importación, exportación y transbordo. El transbordo es carga que llega en un buque y sale en otro sin entrar al territorio aduanero, de modo que no forma parte del comercio exterior del país.

Comparando los primeros doce meses de la serie portuaria con los últimos doce, las toneladas de importación suben un 19,6 % y las de exportación un 1,3 %, mientras el transbordo cae un -85,2 %. El total resultante baja un -13,3 %.

Quien observe únicamente el total concluiría que la zona portuaria movilizó menos carga. La descomposición muestra que lo que descendió fue el transbordo, mientras la carga de importación aumentaba.

La fuente no informa por qué cambió el transbordo. Decisiones de las navieras, reasignación de rutas o cambios en el reporte son explicaciones posibles que estos datos no permiten distinguir.

11.4 Concentración por país, capítulo y sociedad portuaria

Tabla 10. Índice de concentración por dimensión

Dimensión	HHI	Lectura	Dominio
Capítulo arancelario	433.74	desconcentrado	aduanero
País de origen	1351.38	desconcentrado	aduanero
Sociedad portuaria	3514.24	concentrado	portuario

Fuente: Elaboración propia. Salida del pipeline: comparacion_concentracion.csv (P17, P18, P26).

La canasta de productos tiene un índice de 433,74 y la de orígenes 1.351,38: ambas desconcentradas. La movilización, con 3.514,24, está muy por encima del umbral de 2.500. Una sola sociedad portuaria moviliza el 51,36 % de las toneladas del periodo.

Entre los años completos, el índice bajó de 4.722 en 2018 a 2.988 en 2023 y subió a 3.740 en 2025. El valor de 2026, 4.217, no es comparable: cubre seis meses y solo tres sociedades reportan. Recalculando 2025 con esas mismas tres sociedades el índice sería 4.096, de modo que la mayor parte del salto se explica por el cambio de cobertura del reporte y no por una redistribución entre las que continúan.

El índice mide reparto de toneladas reportadas. No mide capacidad instalada, utilización ni posibilidad real de sustitución entre sociedades, de modo que un valor alto no permite concluir por sí solo que exista un riesgo operativo.

11.5 Especialización por tipo de carga

El índice de concentración trata a las sociedades como si fueran intercambiables. El cruce entre sociedad y tipo de carga muestra que no movilizan lo mismo: una de ellas no registró toneladas de granel en todo el periodo y otra no registró contenedores. El reparto agregado describe cuánto movilizó cada una, no si podrían movilizar la carga de las demás.

11.6 Sociedades sin reporte en 2026

2 sociedades portuarias no aparecen en los reportes de los seis meses observados de 2026. Se verificó mes a mes para descartar un rezago de publicación.

La fuente registra reporte, no operación. Con estos datos solo puede afirmarse que no figuran en los reportes del periodo observado; no puede afirmarse que hayan dejado de operar. La implicación metodológica es relevante: un modelo entrenado sobre el total de la zona interpretaría esa ausencia como una contracción real del comercio.

11.7 Comportamiento temporal de la serie aduanera

La autocorrelación del valor CIF con su rezago de un mes es de 0,917, y con el rezago de doce meses de 0,590. La estacionalidad existe pero es moderada: el índice va de 92,8 en el mes 6 a 104,8 en el mes 8 sobre una base de cien.

Que el mes anterior pese más que el mismo mes del año pasado tiene una consecuencia directa: la referencia exigente para el modelo no es la estacional sino la de repetir el último valor observado.

11.8 Relación entre los dos dominios

La razón mediana entre toneladas portuarias de importación y peso neto aduanero es de 1,16, y la correlación en variaciones mensuales es de 0,115. Las series se mueven en el mismo sentido general pero no son proporcionales, lo cual es esperable: miden universos distintos.

12. Resultados del modelado

12.1 Indicadores elegibles

Tabla 11. Elegibilidad de los indicadores candidatos

Indicador	Dominio	Observaciones	Elegible
cif_usd	aduanero	173	True
peso_netto_kg	aduanero	173	True

Indicador	Dominio	Observaciones	Elegible
toneladas_totales	portuario	102	True
ton_contenerizada	portuario	102	True
TEU	portuario	0	False
arribos	marítimo	0	False
permanencia_media	operacional	0	False

Fuente: Elaboración propia. Salida del pipeline: elegibilidad_indicadores.csv (P46).

Tres de los siete candidatos quedan excluidos porque su fuente no existe: TEU, arribos y permanencia media no tienen ni una sola observación.

12.2 Pronóstico del valor CIF

El mejor conjunto de variables es el que usa la historia propia del indicador y variables de calendario, con un WAPE de 5,875 % sobre veinticuatro cortes. Las tres líneas base obtienen 6,956 % la de repetir el último valor, 6,905 % la de extrapolar la pendiente y 16,487 % la estacional.

Frente a la referencia estacional la mejora es del 64,4 %. Frente a la referencia exigente, que es repetir el último valor observado, la mejora real es del 15,5 %.

La diferencia entre ambas cifras es la razón por la que el trabajo reporta siempre las tres líneas base. Informar únicamente la estacional describiría más la debilidad de esa referencia que la calidad del modelo.

12.3 Análisis de ablación

Tabla 12. Ablación por grupos de variables sobre el pronóstico del valor CIF

Conjunto de variables	Variables	WAPE (%)	Ganancia (pp)
B · A + calendario	7	5.875	0.207
A · historia propia	5	6.082	0.0
D · A + contexto (TRM, ONI)	9	6.133	-0.051
E · integrado completo	16	6.167	-0.085
C · A + PUERTO	10	6.575	-0.493
base · drift	0	6.905	-0.823
base · naive_1	0	6.956	-0.874
base · naive_12	0	16.487	-10.405

Fuente: Elaboración propia. Veinticuatro cortes de validación walk-forward. Salida del pipeline: ablacion_multidominio.csv (P49).

El conjunto que añade variables portuarias obtiene 6,575 %, frente a 6,082 % del que usa solo la historia propia. El modelo integrado completo, con dieciséis variables, obtiene 6,167 %. Las variables de contexto tampoco aportan: 6,133 %.

Añadir el dominio portuario no mejora el pronóstico del valor CIF: lo empeora.

La explicación es coherente con la naturaleza de las fuentes. Ambas miden el mismo comercio y comparten el rezago de publicación, de modo que el puerto no aporta información que la historia del propio valor CIF no contenga ya, y sí consume grados de libertad sobre una muestra corta. La consecuencia para el diseño del producto es directa: el componente predictivo se apoya en el dominio aduanero, y el portuario se conserva por su valor descriptivo y explicativo.

12.4 Pronóstico de indicadores portuarios

Para las toneladas totales, el modelo obtiene 6,613 % frente a 9,174 % de la referencia, una mejora del 27,9 %.

Para la carga contenerizada ocurre lo contrario: la referencia obtiene 8,553 % y el modelo 9,450 %, es decir peor que repetir el último valor observado.

Para la carga contenerizada se recomienda no usar modelo. Un indicador que no se pronostica mejor que la referencia trivial no debe presentarse con un modelo encima.

12.5 Intervalos de predicción

Tabla 13. Cobertura empírica de los intervalos de predicción

Indicador	Ventana	Nominal	Empírica	Cortes	Fuera
toneladas totales	24 cortes	80 %	91,7 %	12	1
toneladas totales	36 cortes	80 %	75,0 %	24	6
ton contenerizada naive 1 v24	24 cortes	80 %	75,0 %	12	3
ton contenerizada naive 1 v36	36 cortes	80 %	75,0 %	24	6

Fuente: Elaboración propia. Método: cuantiles empíricos de los errores fuera de muestra con calibración expansiva. Salida completa: cobertura_intervalos_portuarios.csv (P51).

La cobertura se mide y no se declara. Con 12 cortes evaluables en el caso más corto, el intervalo de confianza de la propia cobertura es amplio: un valor por debajo del nominal no permite concluir que el intervalo esté mal calibrado, del mismo modo que uno por encima no permite concluir que lo esté bien.

13. Modelo de negocios

Lo que sigue es una propuesta potencial de adopción, no un modelo validado comercialmente. No se han realizado entrevistas con usuarios ni pruebas piloto, y por tanto ninguna de estas afirmaciones cuenta con evidencia de demanda.

13.1 Propuesta de valor

Un producto reproducible que integra, actualiza y comunica indicadores aduaneros y portuarios de Buenaventura, con trazabilidad de cada cifra y una declaración explícita de lo que los datos no permiten afirmar.

13.2 Necesidad atendida

Reducir el esfuerzo técnico de descargar, homologar, validar e interpretar dos fuentes que se publican por separado, con formatos que cambian y unidades que no son equivalentes.

13.3 Usuarios potenciales, canales y sostenibilidad

Tabla 14. Componentes del modelo de negocios propuesto

Componente	Descripción
Usuarios potenciales	Entidades públicas, observatorios, universidades, gremios, analistas, importadores, sociedades portuarias y consultores
Producto ofrecido	Tablero, series mensuales, reportes, alertas, pronósticos, archivos de evidencia y actualización automatizada
Canales	Aplicación web, reportes periódicos, repositorio de código, presentaciones y exportación de archivos
Sostenibilidad	Mantenimiento institucional, consultoría, servicio de actualización, adaptación a fuentes privadas o

Componente	Descripción
	código abierto con soporte
Costos	Infraestructura, mantenimiento del pipeline, validación mensual, almacenamiento, soporte y eventuales fuentes comerciales

Fuente: Elaboración propia. Propuesta no validada con usuarios.

13.4 Riesgos

- Cambios de formato en las fuentes, que ya ocurrieron cinco veces en el periodo analizado.
- Rezagos de publicación que impiden usar el dato del mes en curso.
- Desaparición o reestructuración de un conjunto de datos abierto.
- Cambios de cobertura del reporte, como el observado en 2026, que alteran la serie sin que cambie el fenómeno.
- Dependencia completa de datos públicos, sin acceso a información operativa.
- Ausencia de datos de tiempos y buques, que limita el alcance frente a productos comerciales.

14. Estrategias de comunicación

Tabla 15. Estrategia de comunicación por público

Público	Necesidad	Canal	Mensaje	Detalle
Directivos	Saber si algo requiere atención	Vista ejecutiva	Nivel de alerta con su razón	Bajo
Analistas	Preparar el informe mensual	Vistas aduanera y portuaria	Series, composición y variaciones	Medio
Investigadores	Reutilizar series y método	Repositorio y archivos	Datos reconciliados y trazables	Alto
Jurado académico	Evaluar rigor y límites	Documento y sustentación	Qué se midió y qué no se puede afirmar	Alto
Usuarios no técnicos	Entender la lectura	Tablero	Valor frente a volumen en lenguaje corriente	Bajo

Fuente: Elaboración propia.

14.1 Criterios de comunicación

Las alertas se comunican en tres niveles, cada uno acompañado de la razón que lo activó y de una acción de revisión sugerida. Ninguna alerta constituye una orden operativa, y así se indica en la propia tarjeta del tablero.

Las limitaciones se muestran junto al resultado, no en una sección aparte al final. Cuando el producto no puede responder algo, la vista correspondiente lo declara y explica qué haría falta, en lugar de dejar el espacio vacío.

Las asociaciones entre variables se presentan siempre como asociaciones. El documento y el tablero evitan el verbo influir cuando solo existe correlación, y las correlaciones se calculan sobre series diferenciadas para no reportar relaciones espurias por tendencia común.

Las métricas técnicas se acompañan de su lectura en lenguaje corriente. Un WAPE del seis por ciento se explica como que, en promedio, la predicción se aparta un seis por ciento del valor observado. Un intervalo se explica como el rango dentro del cual cabe esperar el valor real, con la advertencia de cuántos cortes lo respaldan.

15. Conclusiones

Cada conclusión corresponde a un resultado del análisis o del modelado, y puede rastrearse hasta un archivo del pipeline.

- El proyecto es viable con el alcance construido: dos dominios integrados sobre 101 meses comunes, con 38 preguntas ejecutadas y 10 cerradas con evidencia de no viabilidad.
- La integración entre dominios es agregada por mes calendario. No existe llave pública que permita una integración directa y no se construyó ninguna por inferencia.
- El valor importado creció un 80,4 % en el periodo común, con un aporte del volumen del 52,2 % y del valor unitario del 47,0 %.
- El total portuario descendió un -13,3 %, pero la carga de importación subió un 19,6 % y lo que cayó fue el transbordo, un -85,2 %.
- La movilización está concentrada, con un índice de 3.514,24, mientras la canasta de productos y de orígenes no lo está. El índice mide reparto, no capacidad ni sustitución.
- El modelo aduanero mejora un 15,5 % frente a la referencia exigente. Añadir el dominio portuario no mejora el pronóstico.

- El aporte del dominio portuario es descriptivo y explicativo: permite distinguir valor de volumen y localizar por qué sociedad portuaria pasa la carga.
- El dominio marítimo y el operativo no son viables con fuentes públicas, y esa conclusión está respaldada por la búsqueda documentada de cuatro vías de acceso.
- Ninguna de las 52 preguntas quedó sin evidencia ni sin justificación.

16. Recomendaciones

- Conservar el modelo aduanero como componente predictivo y el portuario como componente descriptivo, según indica el análisis de ablación.
- No pronosticar la carga contenerizada con modelo: usar la referencia de repetir el último valor, que obtuvo mejor desempeño.
- Repetir la descarga de los microdatos en la próxima publicación para medir el efecto de las revisiones sobre la serie, hoy no evaluable con una sola descarga.
- Traducir los códigos de país y capítulo arancelario a sus nombres oficiales antes de presentar las tablas de composición a un lector no técnico.
- Decidir si el total portuario se modela sobre la zona completa o solo sobre las sociedades que continúan reportando, dado el cambio de cobertura observado en 2026.
- Validar las reglas de alerta con al menos un usuario real antes de considerarlas operativas.
- Gestionar acceso institucional a fuentes de evento si se desea abrir el dominio marítimo en una fase posterior.
- Monitorear los cambios de formato de las fuentes, que en el periodo analizado ocurrieron cinco veces.

17. Fuentes de información

Conforme a las normas APA en su séptima edición, la fecha de consulta se incluye únicamente en las fuentes diseñadas para cambiar con el tiempo y sin versión archivada. Las obras estables, como leyes, normas técnicas y manuales impresos, no la llevan.

American Psychological Association. (2020). Publication Manual of the American Psychological Association (7.^a ed.). APA.

- Banco de la República. (2026). Tasa Representativa del Mercado (TRM) [serie estadística]. Recuperado el 6 de agosto de 2026, de <https://www.banrep.gov.co/es/estadisticas/trm>
- Congreso de la República de Colombia. (2012). Ley 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales. Diario Oficial No. 48.587.
- Congreso de la República de Colombia. (2014). Ley 1712 de 2014, por medio de la cual se crea la Ley de Transparencia y del Derecho de Acceso a la Información Pública Nacional. Diario Oficial No. 49.084.
- Departamento Administrativo Nacional de Estadística. (2025). Estadísticas de Importaciones - IMPO - 2012 A 2024 [conjunto de datos]. Archivo Nacional de Datos. Recuperado el 6 de agosto de 2026, de <https://microdatos.dane.gov.co/index.php/catalog/473>
- Departamento Administrativo Nacional de Estadística. (2026). Estadísticas de importaciones (IMPO) 2025–2026 [conjunto de datos]. Archivo Nacional de Datos. Recuperado el 6 de agosto de 2026, de <https://microdatos.dane.gov.co/index.php/catalog/856>
- Dirección General Marítima. (2026). Estadísticas trimestrales de tráfico y transporte marítimo [publicaciones trimestrales en PDF]. Recuperado el 6 de agosto de 2026, de <https://www.dimar.mil.co/operaciones-estadisticas/estadisticas-de-trafico-maritimo-internacional/publicaciones-estadisticas-trimestrales-de-trafico-maritimo>
- Hyndman, R. J., y Athanasopoulos, G. (2021). Forecasting: Principles and practice (3.^a ed.). OTexts. Recuperado el 6 de agosto de 2026, de <https://otexts.com/fpp3/>
- Instituto Colombiano de Normas Técnicas y Certificación. (2008). NTC 1486: Documentación. Presentación de tesis, trabajos de grado y otros trabajos de investigación. ICONTEC.
- National Oceanic and Atmospheric Administration, Climate Prediction Center. (2026). Oceanic Niño Index (ONI) [serie estadística]. Recuperado el 6 de agosto de 2026, de https://origin.cpc.ncep.noaa.gov/products/analysis_monitoring/ensostuff/ONI_v5.php

Superintendencia de Transporte. (2026). Tráfico portuario marítimo en Colombia [conjunto de datos]. Datos Abiertos Colombia. Recuperado el 6 de agosto de 2026, de <https://www.datos.gov.co/Transporte/Trafico-Portuario-Maritimo-En-Colombia/5r3g-zv5z>

17.1 Condiciones de uso exigidas por las fuentes

El DANE exige la cita textual «Fuente: Departamento Administrativo Nacional de Estadística: www.dane.gov.co» y prohíbe la reproducción de los microdatos en medios que los pongan a disposición de múltiples usuarios sin su visto bueno escrito. Este trabajo reproduce agregados mensuales, no los microdatos originales.

El conjunto de tráfico portuario se publica bajo licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional, que obliga a citar la fuente y a compartir los derivados bajo la misma licencia. La Superintendencia advierte además que sus cifras son referenciales y que solo ella puede certificarlas.

Tabla 16. Verificación de las fuentes en línea citadas

Fuente	Verificada	Actualizada	Cambia
DANE catálogo 473	2026-08-06	2025-12-22	no, periodo histórico cerrado
DANE catálogo 856	2026-08-06	2026-07-22	sí, mensual
Superintendencia de Transporte	2026-08-06	2026-07-01	sí, trimestral
Hyndman y Athanasopoulos	2026-08-06	2026-07-23	sí, edición en línea
Banco de la República (TRM)	2026-08-06	por verificar	sí, diaria
NOAA, índice oceánico	2026-08-06	por verificar	sí, mensual
DIMAR, boletines trimestrales	2026-08-06	2026-08-06	sí, trimestral

Fuente: Elaboración propia. Cada dirección fue consultada el 6 de agosto de 2026 y la fecha de actualización proviene de los metadatos publicados por la propia fuente.

Anexo A. Matriz de trazabilidad P01-P52

Tabla 17. Estado de cada pregunta del análisis exploratorio

Pregunta	Bloque	Estado
P01	Fuentes y viabilidad	ejecutada
P02	Fuentes y viabilidad	ejecutada
P03	Fuentes y viabilidad	ejecutada
P04	Fuentes y viabilidad	ejecutada
P05	Fuentes y viabilidad	no viable
P06	Fuentes y viabilidad	ejecutada
P07	Fuentes y viabilidad	ejecutada
P08	Calidad y estructura	ejecutada
P09	Calidad y estructura	ejecutada
P10	Calidad y estructura	ejecutada
P11	Calidad y estructura	ejecutada
P12	Calidad y estructura	parcial
P13	Calidad y estructura	ejecutada
P14	Calidad y estructura	ejecutada
P15	Aduanas y mercancías	ejecutada
P16	Aduanas y mercancías	ejecutada
P17	Aduanas y mercancías	ejecutada
P18	Aduanas y mercancías	ejecutada
P19	Aduanas y mercancías	ejecutada
P20	Aduanas y mercancías	ejecutada
P21	Aduanas y mercancías	ejecutada
P22	Aduanas y mercancías	parcial
P23	Carga portuaria	ejecutada
P24	Carga portuaria	ejecutada
P25	Carga portuaria	parcial
P26	Carga portuaria	ejecutada
P27	Carga portuaria	ejecutada
P28	Carga portuaria	ejecutada
P29	Carga portuaria	ejecutada
P30	Carga portuaria	ejecutada
P31	Buques y fechas	no viable
P32	Buques y fechas	no viable
P33	Buques y fechas	no viable
P34	Buques y fechas	no viable
P35	Buques y fechas	no viable
P36	Buques y fechas	no viable
P37	Buques y fechas	no viable
P38	Buques y fechas	no viable
P39	Contexto e integración	parcial
P40	Contexto e integración	no viable
P41	Contexto e integración	ejecutada
P42	Contexto e integración	ejecutada
P43	Contexto e integración	ejecutada
P44	Contexto e integración	ejecutada
P45	Contexto e integración	ejecutada
P46	Pronóstico y producto	ejecutada
P47	Pronóstico y producto	ejecutada
P48	Pronóstico y producto	ejecutada

Pregunta	Bloque	Estado
P49	Pronóstico y producto	ejecutada
P50	Pronóstico y producto	ejecutada
P51	Pronóstico y producto	ejecutada
P52	Pronóstico y producto	ejecutada

Fuente: Elaboración propia. Salida del pipeline: matriz_trazabilidad_eda.csv.

Anexo B. Reporte de no viabilidad

Tabla 18. Preguntas cerradas por ausencia de fuente

Pregunta	Tema	Estado
P31	arribos y zarpes por periodo	NO VIABLE
P32	tipos de buque y su composición	NO VIABLE
P33	banderas, procedencias, destinos y rutas	NO VIABLE
P34	horarios y días de arribo, atraque y zarpe	NO VIABLE
P35	diferencia entre tiempos estimados y reales (ETA/ATA, ETD/ATD)	NO VIABLE
P36	permanencia en fondeo, terminal o puerto	NO VIABLE
P37	frecuencias y permanencias por buque, ruta o terminal	NO VIABLE
P38	calidad de identificadores, fechas e itinerarios	NO VIABLE

Fuente: Elaboración propia. Salida del pipeline: reporte_no_viabilidad.csv.

No existe fuente pública con serie histórica tabular. DIMAR publica únicamente boletines trimestrales en PDF, sin desagregación por evento. Los datos de evento (ETA, ATA, ETD, ATD, fondeo, permanencia) provienen de sistemas de terminal o de AIS comercial, sin acceso ni presupuesto.

Estas preguntas no quedaron sin responder. Su respuesta es que la fuente necesaria no existe en el ámbito público, y esa respuesta está documentada con las cuatro vías de acceso que se consultaron.

Anexo C. Preparación para la sustentación

Este anexo es material de apoyo para la exposición oral y no forma parte del cuerpo académico del trabajo.

¿Cuál es el problema?

Los datos aduaneros y portuarios de Buenaventura son públicos pero están separados, cambian de formato y miden cosas distintas. Sin integrarlos no se puede distinguir si el comercio creció porque entró más mercancía o porque la mercancía se encareció.

¿Qué predice el producto?

El valor CIF y el peso neto del mes siguiente en el dominio aduanero, y las toneladas totales en el portuario. La carga contenerizada se describe pero no se modela, porque el modelo resultó peor que la referencia.

¿Qué significa que mejore un 15,5 %?

Que el error del modelo es un 15,5 % menor que el de repetir el último valor observado. Es una mejora modesta y medida, no una estimación optimista.

¿Por qué integrar si no mejora el pronóstico?

Porque el valor de la integración es explicativo. Permite separar volumen de valor unitario y mostrar que la caída del total portuario venía del transbordo, no del comercio. Ninguna fuente aislada permite esa lectura.

¿Qué aporta concretamente el dominio portuario?

Tres cosas: la descomposición del total en importación, exportación y transbordo; la concentración por sociedad portuaria; y la detección del cambio de cobertura del reporte en 2026.

¿Por qué el producto no incluye buques ni tiempos?

Porque no existe fuente pública con serie histórica tabular. Se consultaron cuatro vías y ninguna entrega datos por evento. Está documentado en el anexo B.

¿Quién usaría el producto?

Un analista de comercio exterior que hoy dedica horas a descargar y homologar fuentes antes de poder analizar nada.

¿Cuál es el modelo de negocios?

Una propuesta de adopción, no un modelo validado. No se han hecho entrevistas ni pilotos, y así se declara en el capítulo 13.

¿Cómo se evita la fuga de información?

Todas las variables van rezagadas, los escaladores se ajustan dentro de cada corte y existe una prueba que detiene el proceso si una variable correlaciona casi perfecto con el objetivo del mismo mes.

¿Qué es el HHI?

La suma de los cuadrados de las participaciones. Mide qué tan repartido está algo. Por encima de 2.500 se considera concentrado. Mide reparto, no capacidad.

¿Qué significa una pregunta no viable?

Que se buscó la fuente, se documentó dónde y qué se encontró, y se concluyó que el dato no existe en el ámbito público. Es una respuesta, no una omisión.

¿Cuáles son las limitaciones principales?

El valor CIF está en dólares corrientes, el valor por kilogramo no es un precio, la integración es agregada por mes y las alertas son señales de revisión, no órdenes.

¿Qué harían en una segunda fase?

Repetir la descarga para medir revisiones, traducir los códigos a nombres, validar las alertas con un usuario real y gestionar acceso institucional a datos marítimos.